

Nội dung

- 1 Tập dữ liệu
- 2 Làm sạch dữ liệu
- 3 Giảm dữ liệu

Tập dữ liệu

- Thông thường dữ liệu sẽ được biểu diễn dưới dạng văn bản, ảnh, video, âm thanh, dạng bảng hoặc tổng hợp của nhiều dạng trên.

The diagram shows a table with 14 rows and 7 columns. The columns are labeled: id, outlook, temperature, humidity, windy, play. The rows are labeled with numbers 1 to 14. The values are the data entries in the cells. A bracket on the left side of the table is labeled 'Rows', a bracket on the top is labeled 'Columns', and an arrow pointing to a cell is labeled 'Values'.

	id	outlook	temperature	humidity	windy	play
1	1	sunny	85	85	FALSE	no
2	2	sunny	80	90	TRUE	no
3	3	overcast	83	86	FALSE	yes
4	4	rainy	70	96	FALSE	yes
5	5	rainy	68	80	FALSE	yes
6	6	rainy	65	70	TRUE	no
7	7	overcast	64	65	TRUE	yes
8	8	sunny	72	95	FALSE	no
9	9	sunny	69	70	FALSE	yes
10	10	rainy	75	80	FALSE	yes
11	11	sunny	75	70	TRUE	yes
12	12	overcast	72	90	TRUE	yes
13	13	overcast	81	75	FALSE	yes
14	14	rainy	71	91	TRUE	no

Phân tích dữ liệu thông minh

Tiền xử lý dữ liệu

TS. Nguyễn Tiến Huy
ntienhuy@fit.hcmus.edu.vn

Các nguồn dữ liệu

- Data hub: <https://datahub.io/>
- The World Bank: <https://data.worldbank.org/>
- United States Government: <https://www.data.gov/>
- Kaggle: <https://www.kaggle.com/competitions>
- ...

Làm sạch dữ liệu (data scrubbing)

- Nhằm đảm bảo dữ liệu thỏa mãn các tính chất sau:
 - Chính xác
 - Đầy đủ
 - Đồng nhất
 - Thống nhất

Các kỹ thuật làm sạch dữ liệu

- <https://colab.research.google.com/drive/1ACHarvfN5syFVlxvCkX8di2YbWuS-9DV>

Các phương pháp làm giảm dữ liệu

- Filtering and sampling
- Binned algorithm
- Dimensionality reduction

Cảm ơn đã theo dõi!